

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

**«САРАТОВСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ ИМЕНИ Н.Г.ЧЕРНЫШЕВСКОГО»**

Кафедра теоретических основ
компьютерной безопасности и
криптографии

РЕФЕРАТ

Поиск аномалий во временных рядах нейронными сетями

студентки 5 курса 531 группы
направления 10.05.01—Компьютерная безопасность
факультета КНиИТ
Ежовой Елены Дмитриевны

Проверил

доцент

подпись, дата

И. И. Слеповичев

Саратов 2024

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1 Временные ряды и аномалии в них	4
2 Методы обнаружения аномалий в временных рядах с использованием различных подходов	12
2.1 STL декомпозиция	13
2.2 Рекуррентные нейронные сети (RNN)	14
2.3 Автокодировщики	17
2.4 Forecasting-based	18
2.5 Isolation Forest	21
ЗАКЛЮЧЕНИЕ	23
СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ	24

ВВЕДЕНИЕ

За прошедшее десятилетие человечество достигло значительных успехов в сфере информационных технологий. С каждым годом увеличивается объём данных, собираемых из различных источников. Для эффективной эксплуатации сложных технологических систем нужны системы мониторинга и различные методы аналитики, позволяющие контролировать и управлять процессом сбора полезной информации. Данные в информационных системах могут быть представлены в различных форматах, нередко их значения берутся из непрерывных систем, поведение которых нужно описать или предсказать. Временные ряды составляют значительную часть этих данных, поскольку они фиксируют изменения показателей во времени. Такой тип данных имеет широкое применение, от мониторинга состояния оборудования до анализа поведения пользователей в интернете. Для корректной систематизации данных хранящихся во временных рядах необходимо иметь аппарат способный выделять особенные места, в которых значения выборки значительно отличаются. Такие отклонения в исследуемых данных называются аномалиями. Они могут сигнализировать о неполадках, угрозах безопасности или иных критических ситуациях. Это делает задачу анализа временных рядов важной как для бизнеса, так и для науки.

Аномалии предоставляют ценные сведения о работе систем, помогая своевременно выявлять сбои и реагировать на них. Однако их анализ сопряжён с рядом проблем, таких как высокая размерность данных, сложности интерпретации и высокая стоимость ошибок (ложных срабатываний или пропущенных аномалий). Это делает задачу поиска аномалий актуальной и требующей разработки более эффективных решений. Одним из таких решений является использование различных нейронных сетей.

1 Временные ряды и аномалии в них

Временные ряды представляют собой последовательность наблюдений, упорядоченных во времени.

В качестве примеров временных рядов могут выступать:

1. состояние операционной системы (загруженность CPU\GPU и накопителей);
2. стоимость валют и акций в определённый момент времени;
3. анализ поведения пользователей в сети и отслеживание трафика;
4. прогноз погоды;
5. кардиограмма.

Характерной особенностью временных рядов является зависимость текущих значений от предшествующих, равное расстояние по времени между измерениями, а также возможность из данных предыдущего периода восстановить поведение процесса в текущем и последующих периодах, что требует применения специализированных методов анализа, которые основываются на характеристиках временных рядов.

Временные ряды по характеру данных подразделяются на два типа: непрерывные и дискретные.

Непрерывные временные ряды фиксируют значения величин в любой момент времени, позволяя отобразить изменения без перерывов. Такие ряды характерны для процессов, где измерения могут проводиться постоянно, например, изменение температуры, напряжения или других параметров.

Дискретные временные ряды, напротив, содержат данные, зарегистрированные через равные интервалы времени. Это могут быть показатели численности населения, изменения стоимости акций или объем производства. Дискретные ряды формируются двумя способами:

1. выборка из непрерывных временных рядов с регулярными интервалами (например, данные о численности населения, собственном

капитале компании, денежной массе или стоимости акций). Такие ряды называются моментными;

2. накопление значений переменной за определённый период (например, объем производства, количество осадков или объем импорта). Такие ряды называются интервальными [1].

При анализе временных рядов важным этапом является определение основных компонент, влияющих на динамику показателей. Таковыми являются трендовая компонента, сезонная компонента, циклическая компонента, случайная компонента. Ниже описаны представлены их описания и особенности.

Трендовая компонента (или тенденция) характеризует долгосрочное направление изменения временного ряда. Она отражает общее поведение данных на протяжённом интервале времени, показывая, растут ли значения, снижаются или остаются неизменными.

Существует несколько типов трендов в временных рядах:

1. восходящий тренд – это тренд, при котором значения данных постепенно увеличиваются с течением времени;

2. нисходящий тренд – это тренд, при котором значения данных постепенно уменьшаются с течением времени;

3. горизонтальный тренд – это тренд, при котором значения остаются неизменными с течением времени;

4. нелинейный тренд – тренд, демонстрирующий более сложную картину изменений с течением времени, включая восходящие или нисходящие тенденции, которые со временем меняют направление или величину;

5. затухающий тренд – тренд, при котором скорость изменений со временем замедляется.

На рисунке 1 представлены тренды временных рядов.

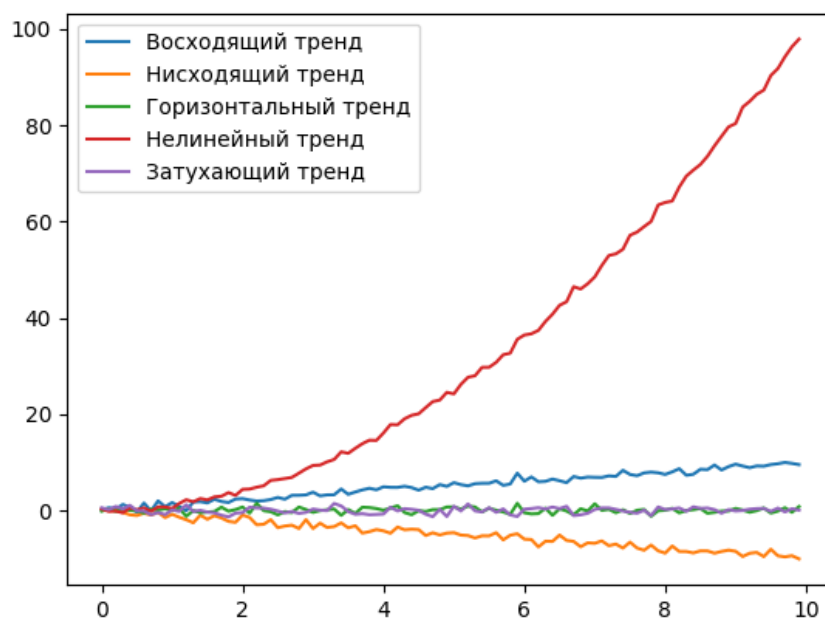


Рисунок 1 – визуализация трендов временных рядов.

Сезонная компонента описывает регулярные, периодически повторяющиеся колебания в течение более коротких интервалов, например, всплески спроса в праздники. Такие колебания имеют фиксированную величину, направление и чётко определённые временные рамки.

Существует несколько типов сезонности в данных временных рядов, в том числе:

1. еженедельная сезонность - тип сезонности, который повторяется в течение 7-дневного периода;
2. ежемесячная сезонность - тип сезонности, который повторяется в течение 30 или 31-дневного периода;
3. ежегодная сезонность - тип сезонности, который повторяется в течение 365 или 366 дней;
4. праздничная сезонность - тип сезонности, вызванный какими-либо событиями, такими как праздники, фестивали или спортивные мероприятия.

На рисунке 2 представлены временные ряды с описанными выше сезонными компонентами.

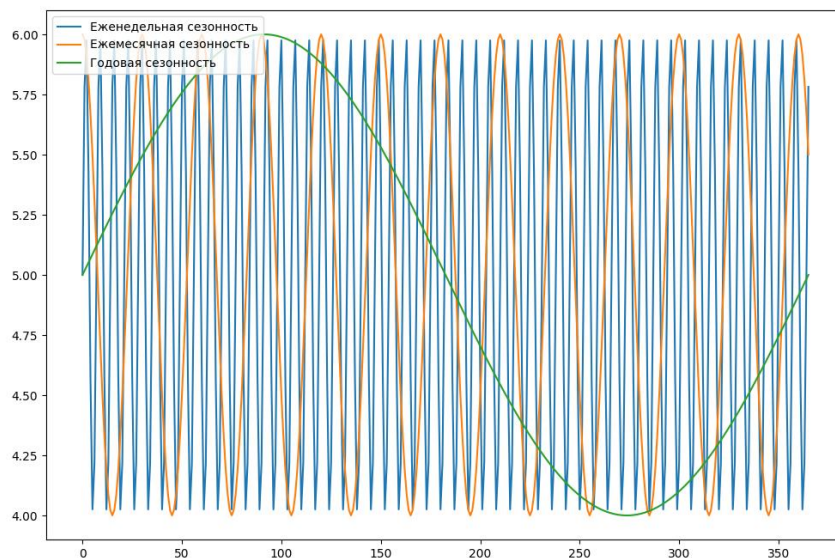


Рисунок 2 – визуализация сезонности временных рядов.

Циклическая компонента представляет собой повторяющиеся колебания, не привязанные к строго определённому периоду. Их длительность и амплитуда варьируются, и они продолжаются дольше, чем нерегулярные флуктуации, но недостаточно долго, чтобы считаться трендом. На рисунке 3 представлен временной ряд с ярко выраженными циклическими колебаниями. В данном случае цикличность возникает за счёт наложения двух синусоидальных функций с разными периодами, что приводит к сложным, но регулярным изменениям значений со временем.




Рисунок 3 – визуализация цикличности временных рядов.

Случайная компонента обусловлена влиянием случайных факторов на исследуемый процесс. Данная компонента проявляется в виде непредсказуемых изменений значений временного ряда и обычно выражается повышенной изменчивостью данных, не связанной с систематическими или периодическими факторами. На рисунке 4 показаны два временных ряда: первый представляет собой синусоидальную функцию с линейным трендом, а второй — тот же ряд, но с добавленной случайной компонентой в виде шума. Этот график иллюстрирует, как случайная компонента может сливаться с основными данными временного ряда, затрудняя выявление ключевых закономерностей [2].

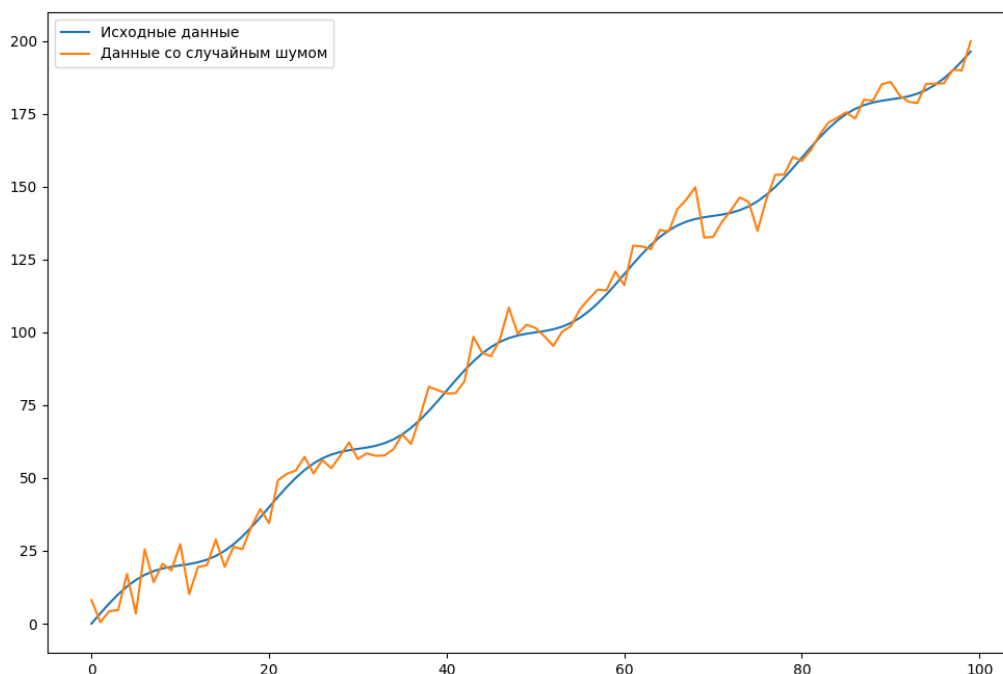


Рисунок 4 – визуализация случайной компоненты временного ряда.

Временные ряды делятся по наличию или отсутствию трендов и сезонных компонент на стационарные и нестационарные.

Стационарные временные ряды характеризуются тем, что их статистические свойства остаются постоянными во времени. Это означает, что среднее значение, дисперсия и автокорреляция не зависят от сдвига во времени. Иными словами, временные ряды с трендами или сезонностью не являются стационарными — тренд и сезонность будут влиять на значение временного ряда в разное время. Такая устойчивость свойств делает

стационарные ряды удобными для моделирования и прогнозирования, так как предполагается, что их поведение будет одинаковым в будущем.

Нестационарные временные ряды, напротив, характеризуются изменением статистических свойств со временем. У таких рядов среднее значение, дисперсия или автокорреляция могут меняться. Это делает анализ и прогнозирование более сложными, так как такие ряды могут отражать тренды, сезонность или внезапные структурные изменения [3].

К основным задачам в области временных рядов можно отнести следующие:

1. прогнозирование следующего значения временного ряда;
2. классификация, кластеризация, поиск паттернов временных рядов;
3. обнаружение выбросов или аномалий во временных рядах;
4. генерация, моделирование или выделение признаков временных рядов;
5. модификация значений временного ряда.

При анализе временных рядов могут быть обнаружены аномалии в полученных данных.

Аномалии — это наблюдения, которые значительно отклоняются от ожидаемого поведения временного ряда. Такие отклонения могут быть вызваны ошибками измерений, изменениями внешней среды или нарушениями в системе. Выявление аномалий критически важно в таких областях, как обнаружение мошенничества, мониторинг оборудования, прогнозирование природных катастроф и медицинская диагностика.

Аномалии могут быть трех типов: точечные, коллективные и контекстные.

Точечные аномалии - единичные значения, сильно отклоняющиеся от ожидаемых. Например, внезапное резкое увеличение трафика в сети. Такие значения называются выбросами, они сильно влияют на статистические показатели процесса и их легко обнаружить, установив пороговые значения для наблюдаемой величины.

Коллективные аномалии - набор подряд идущих наблюдений, отклоняющихся от нормального поведения. Например, длительное превышение температуры оборудования. Такое аномальное поведение сложно отследить ввиду того, что в отдельно взятых точках функция может вести себя стабильно, однако в совокупности может быть отклонение от нормы. К такому аномальному поведению можно отнести, например, изменение формы сигнала, изменение статистических показателей (среднее значение, мода, медиана, дисперсия), появление взаимной корреляции между двумя параметрами, небольшие или краткосрочные аномальные изменения амплитуды. В данном случае задача заключается в распознавании аномального поведения параметров, которое нельзя выявить обычными статистическими методами.

Разница между точечными и коллективными аномалиями изображена на рисунке 5.




Рисунок 5 – точечные и коллективные аномалии.

Контекстные аномалии - наблюдения, отклоняющиеся от нормы в определённом контексте. Например, высокая температура может быть нормальной в летний день, но аномальной зимой. Контекстная аномалия представлена на рисунке 6 [4].




Рисунок 6 – набор значений, изменяющийся в зависимости от контекста [4].

Под задачами анализа аномалий понимается разделение данных на нормальные и аномальные наблюдения. При этом важно учитывать особенности подхода, использующегося при анализе данных. Например, при использовании алгоритма важно понимать, насколько хорошо он устойчив к шумным данным и как часто бывают ошибочные показатели.

2 Методы обнаружения аномалий в временных рядах с использованием различных подходов

В процессе поиска аномалий на реальных данных существенной сложностью является то, что данные не размечены, поэтому изначально строго не определено, что такое аномалия и по каким правилам ее искать. В таких ситуациях необходимо применять методы обучения без учителя, при этом модели самостоятельно определяют взаимосвязи и характерные законы в данных.

Методы, используемые для поиска аномалий, можно разделить на следующие группы [4]:

1. proximity-based – метод для выявления аномалии на основе информации о близости параметров или последовательности параметров фиксированной длины. Этот метод подходит для выявления точечных аномалий и выбросов, но он не позволяет выявить изменения в форме сигнала. Он ориентирован на поиск значений, существенно отклоняющихся от поведения всех остальных точек;

2. prediction-based – метод для построения прогнозной модели и сравнение прогноза и фактической величины. Он лучше всего применим ко временным рядам с выраженными периодами, циклами или сезонностью. Пример построения модели изображен на рисунке 7;

3. reconstruction-based - метод, основанный на реконструкции фрагментов данных. Так как он использует реконструкцию фрагмента данных, то он может выявлять как точечные аномалии, так и групповые аномалии, в том числе изменения в форме сигнала.




Рисунок 7 – моделирование временного ряда методом prediction-based [4].

2.1 STL декомпозиция

STL декомпозиция, также известная как сезонно-трендовая декомпозиция, основанная на LOESS (locally estimated scatterplot smoothing, или же локально оцененное сглаживание диаграммы рассеяния) — метод, использующий для нахождения аномалий подход разложения временного ряда на его составляющие. В методе STL используются локально подобранные регрессионные модели для разложения временного ряда на компоненты тренда, сезонности и остатка [5].

Метод эффективно работает для сезонных временных рядов (обладающих ярко выраженным свойством сезонности), которые являются наиболее распространенным типом временных рядов.

Алгоритм STL сглаживает временные ряды с помощью LOESS в двух циклах: внутренний цикл выполняет итерацию между сезонным сглаживанием и сглаживанием тренда, а внешний цикл минимизирует влияние выбросов. В ходе внутреннего цикла сезонный компонент вычисляется первым и удаляется для вычисления компонента тренда. Остаток вычисляется путем вычитания сезонного и трендового компонентов из временных рядов.

Компоненты анализа STL временного ряда связаны следующим образом:

$$y_i = s_i + t_i + r_i$$

или

$$y_i = s_i \cdot t_i \cdot r_i$$

где y_i - значение временного ряда в точке i ;

s_i - значение сезонного компонента в точке i ;

t_i - значение компонента тренда в точке i ;

r_i - значение компонента остатка в точке i .

При разложении на компоненты исходного набора данных упрощается поиск аномального поведения при визуальном осмотре. Пример продажи лекарств в Австралии с 2013 по 2014 года с разложением на компоненты представлен на рисунке 8.




Рисунок 8 – разложение временного ряда методом STL декомпозиции [6].

В последней компоненте ряда можно выделить точки, которые наиболее сильно удалены от исходной оси. Данный подход может использоваться как в нейронных сетях, так и отдельно, например, на основе заданного порога допустимых значений. В случае, когда используется нейронная сеть, исходный временный ряд может быть преобразован к одной из компонент с целью более удобного анализа.

Преимущества STL декомпозиции заключаются в возможности контроля пользователем плавности трендового цикла и скорости изменения, а также в устойчивости к выбросам.

2.2 Рекуррентные нейронные сети (RNN)

Рекуррентные нейронные сети (RNN) — это класс нейронных сетей, которые хороши для моделирования последовательных данных, таких как

временные ряды или естественный язык. Наиболее распространенными представителями этого класса являются: RNN, LSTM и GRN. Рассмотрим более подробно каждый из них [7].

Рекуррентные нейронные сети (RNN, Recurrent Neural Networks) — это тип нейронных сетей, предназначенных для обработки таких данных, как текст, временные ряды, аудио или видео. Главная особенность RNN — наличие скрытого состояния, которое «помнит» информацию о предыдущих шагах во входной последовательности.

RNN определяется по формуле:

$$h_t = \tanh(W_h x_t + U_h h_{t-1} + b_h)$$

где x_t - входной вектор на шаге t ;

h_t - скрытое состояние на шаге t ;

W_h, U_h - матрицы весов для входного и скрытого состояний соответственно;

b_h - смещение;

\tanh - активационная функция.

Модификацией RNN является LSTM, который позволяет эффективно учитывать долгосрочные зависимости в последовательностях за счёт использования механизма гейтов: забывающего, входного и выходного.

Забывающий гейт - определяет, какую часть предыдущей информации забыть:

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)$$

Гейт ввода - обновляет клеточное состояние, добавляя новую информацию:

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)$$

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)$$

Обновление клеточного состояния:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

Гейт вывода:

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)$$

Обновление скрытого состояния:

$$h_t = o_t \odot \tanh(c_t)$$

где \odot - поэлементное произведение; σ – сигмоида.

GRU — это упрощённая версия LSTM, которая объединяет клеточное и скрытое состояния. Она использует два гейта: обновления и сброса.

Гейт обновления – определяет, сколько информации из предыдущего состояния нужно сохранить:

$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z)$$

Гейт сброса – контролирует, сколько информации из предыдущего состояния использовать для обновления:

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r)$$

Временное новое состояние:

$$\tilde{h}_t = \tanh(W_h x_t + r_t \odot (U_h h_{t-1}) + b_h)$$

Новое скрытое состояние:

$$h_t = z_t \odot h_{t-1} + (1 - z_t) \odot \tilde{h}_t$$

Схемы каждого из рассмотренных типов представлены на рисунке 9.




Рисунок 9 – схемы рекурсивных нейронных сетей [8].

Для обнаружения аномалий во временных рядах можно применить рекуррентную нейронную сеть с памятью LSTM.

Недостатком рекуррентной нейронной сети является возможность ее применения только для прогнозируемых временных рядов, что не позволяет использовать ее в качестве универсального решения. Применение RNN LSTM для временного ряда представлена на рисунке 10.

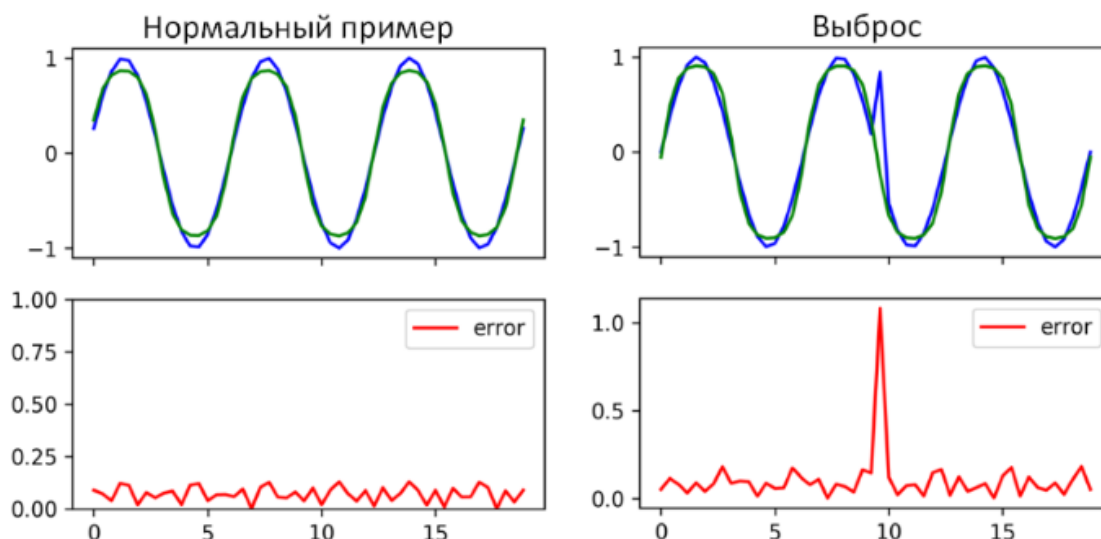


Рисунок 10 – пример работы рекуррентной нейронной сети с ячейками памяти LSTM [9].

В данном случае была успешно найдена аномалия ввиду большой ошибки прогнозирования. В некоторых случаях применение RNN LSTM может быть недостаточно, поскольку она применима к малому количеству метрик, однако она может выступать как вспомогательный инструмент для выявления аномалий.

2.3 Автокодировщики

Автокодировщик — это архитектура нейронных сетей, предназначенная для обучения без учителя с использованием метода обратного распространения ошибки. Базовая структура автокодировщика представляет собой сеть прямого распространения без обратных связей, напоминающую перцептрон. Она включает входной слой, скрытый слой и выходной слой. Однако в отличие от перцептрона, количество нейронов в выходном слое автокодировщика всегда равно количеству нейронов во входном слое [10].

Автокодировщик состоит из двух частей: кодировщика, преобразующего входные данные в сжатый код, и декодировщика, восстанавливающего данные из этого кода. Центральный скрытый слой автокодировщика называется bottleneck-слоем, и его отличительной особенностью является минимальная размерность среди всех скрытых слоев. Размерность слоев автокодировщика уменьшается при переходе от входного слоя к bottleneck-слою и увеличивается

при движении от bottleneck-слоя к выходному. Последовательность слоев от входного слоя до bottleneck-слоя образует кодировщик, а от bottleneck-слоя до выходного слоя — декодировщик [11].

Примерная схема работы автокодировщика представлена на рисунке 11.

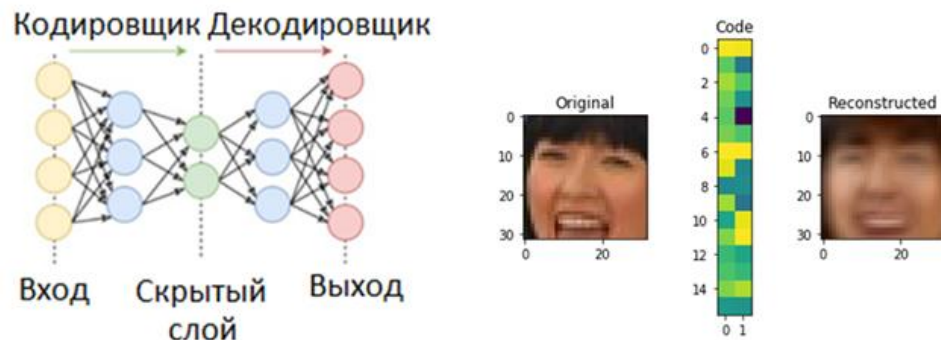


Рисунок 11 – схема работы автокодировщика [4].

Основная идея заключается в том, что автокодировщик обучается восстанавливать «нормальные» временные ряды, минимизируя ошибку реконструкции. Когда автокодировщик сталкивается с аномальными данными, ошибка реконструкции резко возрастает, что позволяет идентифицировать аномалии.

Таким образом задача автокодировщика заключается в нахождении временных индексов r_0, \dots, r_n , соответствующих аномальным элементам во входном векторе X . Данный эффект достигается за счет поиска квадратичной ошибки. Значительным недостатком автокодировщиков является плохая локализация аномалий.

2.4 Forecasting-based

Forecasting-based — это метод обнаружения аномалий во временных рядах, который основывается на прогнозировании значений временного ряда и сравнении фактических данных с предсказанными. Если разница между прогнозируемыми и реальными значениями превышает установленный порог, то это указывает на аномалию [12].

Применение данного метода сопряжено с рядом трудностей.

Во-первых, требуется определить параметры модели, такие как порядок дифференцирования, количество авторегрессий и значения коэффициентов ошибки прогноза.

Во-вторых, для каждого нового временного ряда необходимо разрабатывать и адаптировать новую модель прогнозирования, что может быть трудоемким процессом.

В-третьих, значительным ограничением является необходимость обеспечения стационарности временного ряда после дифференцирования. Иными словами, сигнал должен быть инвариантен ко времени, что представляет собой серьезное препятствие в анализе данных, демонстрирующих ярко выраженные тренды или сезонные компоненты [10].

Для применения этого подхода требуется использование модели, способные прогнозировать значения временного ряда. Это может быть как нейронная сеть, так и статистическая модель. Среди них:

1. ARMA (авторегрессия — скользящее среднее): объединяет две базовые модели временных рядов — авторегрессию (AR) и скользящее среднее (MA);

2. ARIMA (модель Бокса — Дженкинса): представляет собой расширение ARMA, предназначенное для работы с нестационарными временными рядами;

3. SARIMA (сезонная авторегрессия — интегрированное скользящее среднее): углубляет возможности ARIMA за счёт учета сезонных трендов. Эти модели относятся к наиболее популярным математическим методам анализа и прогнозирования стационарных временных рядов;

4. RNN (рекуррентные нейронные сети): тип нейронной сети, специально разработанный для обработки последовательностей данных, включая временные ряды;

5. LSTM (long short-term memory): особая архитектура рекуррентной нейронной сети, решающая проблему исчезающего градиента, характерную для стандартных RNN.

Для проверки этой техники можно использовать популярный модуль временных рядов под названием *fbprophet* [7]. Этот модуль специально учитывает стационарность и сезонность, и может быть настроен с помощью некоторых гиперпараметров. На рисунке 12 представлен тестовый временный ряд для графика прогнозов и визуализации аномалий.




Рисунок 12 – временный ряд [10].

Построенный график прогнозов и визуализированные аномалии тестового временного ряда представлены на рисунке 13.




Рисунок 13 – визуализация аномальных и прогнозируемых точек [10].

К плюсам данного подхода можно отнести [10]:

1. обработку различных параметров сезонности, например, месячные или годовые, а также встроенную поддержку всех метрик временных рядов;

2. алгоритм хорошо справляется с пограничными случаями.

Однако несмотря на очевидные преимущества имеется также недостаток, который выражается в сценариях с ограниченными данными. Качество прогнозирования в условиях ограниченных данных будет ниже, как и точность обнаружения аномалий.

2.5 Isolation Forest

Метод Isolation Forest, основанный на деревьях решений и случайных лесах, широко используется для обнаружения выбросов и аномалий во временных рядах.

В отличие от других методов обнаружения выбросов, Isolation Forest фокусируется на прямой идентификации аномалий, не прибегая к профилированию нормальных данных. Аномалии определяются как редкие и значительно отличающиеся точки данных. Метод изолирует аномалии без применения мер расстояния (например, Евклидово расстояние или DTW), либо энтропийных подходов (взаимная информация). Isolation Forest строится на основе деревьев решений, аналогично другим ансамблевым методам.

Этапы применения метода:

1. задание параметра модели, определяющего долю выбросов в данных;
2. обучение модели и выполнение предсказания для выявления выбросов;
3. визуализация временного ряда с обнаруженными аномалиями для оценки качества обнаружения.

Для реализации всех этапов можно использовать библиотеки Python matplotlib, pandas, и sklearn.

На рисунке 14 представлены аномальные точки временного ряда (см. рис. 12), найденные методом Isolation Forest.




Рисунок 14 – обнаружение аномалий с использованием алгоритма Isolation Forest [10].

На рисунке показано, что данный метод успешно выявил аномальные точки, однако в начале ряда некоторые точки были ошибочно классифицированы как аномальные. Недостатком данного подхода является растущее число признаков, которое может быстро начать влиять на вычислительную производительность.

ЗАКЛЮЧЕНИЕ

Анализ временных рядов и поиск аномалий в них играют ключевую роль в современной аналитике данных, так как позволяют своевременно выявлять отклонения, сигнализирующие о потенциальных проблемах. Несмотря на сложности, связанные с обработкой высокоразмерных данных и выбором подходящих методов, использование нейронных сетей и алгоритмов машинного обучения предоставляет эффективные инструменты для решения этих задач.

Каждый метод, рассмотренный в реферате, обладает своими преимуществами и недостатками, что позволяет выбрать нужный подход в зависимости от специфики данных и требований задачи. Например, STL-декомпозиция удобна для временных рядов с выраженной сезонностью, автокодировщики и рекуррентные нейронные сети хорошо справляются с выявлением сложных паттернов, а методы, такие как Isolation Forest, позволяют обнаруживать редкие и выбивающиеся данные без предварительной разметки.

Дальнейшее развитие области включает оптимизацию существующих алгоритмов, интеграцию нескольких методов для повышения точности обнаружения аномалий, а также улучшение интерпретируемости результатов. Это особенно важно для приложений в критически значимых областях, таких как мониторинг оборудования, финансовый анализ, медицинская диагностика и системы безопасности.

Таким образом, исследования и разработки в области анализа временных рядов остаются актуальными и востребованными, открывая новые возможности для автоматизации, повышения эффективности систем и улучшения качества принимаемых решений.

СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ

1. Different Types of Time-Series Data [Электронный ресурс]: - URL: <https://www.timescale.com/blog/time-series-introduction#different-types-of-time-series-data> (дата обращения 11.12.2024) - Англ.яз.
2. Components of Time Series Data [Электронный ресурс]: - URL: <https://www.geeksforgeeks.org/components-of-time-series-data/> (дата обращения 11.12.2024) - Англ.яз.
3. Stationarity and differencing [Электронный ресурс]: - URL: <https://otexts.com/fpp2/stationarity.html> (дата обращения 11.12.2024) - Англ.яз.
4. Поиск аномалий во временных рядах [Электронный ресурс]: - URL: <https://habr.com/ru/articles/588320/> (дата обращения 21.12.2024) - Рус.яз.
5. STL: A Seasonal-Trend Decomposition Procedure Based on LOESS, [Электронный ресурс]: - URL <https://www.wessa.net/download/stl.pdf> (дата обращения 22.12.2024) - Англ.яз.
6. Временные ряды [Электронный ресурс]: - URL: <https://education.yandex.ru/handbook/ml/article/vremennyye-ryady> (дата обращения 24.12.2024) - Рус.яз.
7. Recurrent Neural Networks, [Электронный ресурс]: - URL <https://www.ibm.com/cloud/learn/recurrent-neural-networks> (дата обращения 24.12.2024) - Англ.яз.
8. Рекуррентные нейронные сети (RNN) с Keras [Электронный ресурс]: - URL: <https://habr.com/ru/articles/487808/> (дата обращения 25.12.2024) - Рус.яз.
9. Ищем аномалии и предсказываем сбои с помощью нейросетей [Электронный ресурс]: - URL: <https://habr.com/ru/companies/krista/articles/478392/> (дата обращения 26.12.2024) - Рус.яз.
10. Anomaly Detection in Time Series [Электронный ресурс]: - URL: <https://neptune.ai/blog/anomaly-detection-in-time-series> (дата обращения 26.12.2024) - Англ.яз.

11. Как находить аномалии в трафике с помощью ML [Электронный ресурс]: - URL: <https://ptresearch.media/articles/kak-nahodit-anomalii-v-trafike-s-pomoshhyu-ml> (дата обращения 2.12.2024) - Рус.яз.

12. Forecasting: What It Is, How It's Used in Business and Investing [Электронный ресурс]: - URL: <https://www.investopedia.com/terms/f/forecasting.asp> (дата обращения 21.12.2024) - Англ.яз.